Kertaus: Dia 6

Painotus niissä asioissa, jotka jäivät kyselyssä epävarmoiksi tai puutteellisiksi

1. Overfitting / ylioppiminen

Overfitting tarkoittaa sitä, että malli mukautuu liian tarkasti training datan yksityiskohtiin, kohinaan ja satunnaisiin erityispiirteisiin. Tällöin training datalla tulos voi näyttää erittäin hyvältä, mutta uusi, aiemmin näkemätön data ennustuu huonommin.

• Hyvä malli ei vain muista training dataa, vaan oppii rakenteita, jotka yleistyvät myös uuteen dataan.

• Ylioppiminen voi näkyä suurena erona training- ja testisuorituskyvyn välillä.

• Paljon piirteitä tai liian monimutkainen malli voi kasvattaa ylioppimisen riskiä, koska mallilla on enemmän mahdollisuuksia sovittua training datan sattumanvaraisiin yksityiskohtiin.

Muistisääntö

Training data erittäin hyvä + uusi data selvästi heikompi = mahdollinen overfitting.

2. Validointi ja yleistyminen

Validointi tarkoittaa mallin testaamista datalla, jota ei ole käytetty mallin kouluttamiseen. Sen tarkoitus on selvittää, kuinka hyvin malli yleistyy uusiin havaintoihin.

• Accuracy, precision ja recall pitäisi arvioida testidatasta tai muuten aiemmin näkemättömästä datasta.

• Training accuracy voi olla liian optimistinen, koska malli on jo sovitettu juuri siihen dataan.

• Koneoppimismallin tärkein tavoite on hyvä suorituskyky uudella datalla, ei mahdollisimman korkea training score.

3. Split validation

Split validationissa data jaetaan kahteen osaan: training set kouluttaa mallin ja test set arvioi sen.

• Jako tehdään tavallisesti satunnaisesti. Esimerkkinä 70 % trainingiin ja 30 % testiin.

• test_size määrää, kuinka suuri osa datasta menee testaukseen.

• random_state ei määrää prosenttijakoa, vaan lukitsee satunnaisuuden siemenen niin, että sama jako voidaan toistaa.

• Heikkous: testiin varattu osa jää pois kyseisen mallin koulutuksesta. Pienessä datasetissä tämä voi olla merkittävä haitta.

4. Cross-validation / ristiinvalidointi

Cross-validationissa data jaetaan k yhtä suureen osaan eli foldiin. Tässä k tarkoittaa foldien määrää, ei niiden kokoa.

• Malli koulutetaan yhteensä k kertaa.

• Jokaisella kierroksella k-1 foldia käytetään trainingiin ja yksi fold testaukseen.

• Jokainen fold toimii vuorollaan testidatana.

• Lopullinen suorituskyky saadaan yleensä kierrosten tulosten keskiarvosta.

10-fold esimerkki	Mitä tapahtuu?
k = 10	Data jaetaan 10 foldiin.
Kierros 1	9 foldia trainingiin, 1 testiin.
Kierrokset 2-10	Testifoldi vaihtuu joka kierroksella.
Lopuksi	Tulokset keskiarvoistetaan.

5. Miksi cross-validation auttaa pienessä datasetissä?

Pienessä aineistossa yksittäinen satunnainen train/test-jako voi vaikuttaa tulokseen paljon. Cross-validation hyödyntää dataa tehokkaammin, koska eri kierroksilla kaikki havainnot osallistuvat sekä koulutukseen että testaukseen.

• Arvio ei riipu yhtä voimakkaasti yhdestä sattumanvaraisesta jaosta.

• Trainingiin saadaan useimmilla kierroksilla suurempi osa aineistosta kuin tavallisessa yhden jaon testissä.

• Usean kierroksen keskiarvo antaa yleensä vakaamman arvion mallin suorituskyvystä.

6. random_state ja cherry picking

random_state lukitsee satunnaisuuden siemenen. Saman arvon käyttäminen tuottaa saman train/test-jaon uudelleen, mikä parantaa toistettavuutta.

Cherry picking tarkoittaa tässä sitä, että random_state-arvoa vaihdellaan tarkoituksella, kunnes saadaan poikkeuksellisen hyvä testitulos. Tämä vääristää arviointia, koska silloin valitaan itselle suotuisa datanjako sen sijaan, että mitattaisiin mallin todellista yleistymiskykyä.

Muistisääntö

random_state = toistettavuus. Sitä ei viritetä paremman scoren saamiseksi.

7. Mallin monimutkaisuus ja piirteiden määrä

Kun featureiden määrä kasvaa, mallin mahdollisuus löytää training datasta myös sattumanvaraisia yhteyksiä kasvaa. Siksi mallin monimutkaisuuden kasvu voi lisätä overfitting-riskiä.

• Useampi feature ei automaattisesti tarkoita parempaa mallia.

• Tavoite on löytää yleistyviä rakenteita, ei rakentaa sääntöjä, jotka selittävät vain yhden aineiston täydellisesti.

Tiivistelmä kokeeseen

Termi	Ydinajatus
Overfitting	Malli oppii training datan erityispiirteitä liian tarkasti eikä yleisty hyvin.
Validation	Mallia arvioidaan aiemmin näkemättömällä datalla.
Split validation	Yksi jako: training set + test set.
Cross-validation	k foldia, k koulutusta, jokainen fold vuorollaan testinä, tulokset keskiarvoistetaan.
random_state	Tekee satunnaisesta jaosta toistettavan.
Cherry picking	Valitaan tarkoituksella suotuisa jako paremman tuloksen saamiseksi.
Hyvä malli	Yleistyy uuteen dataan, ei vain suoriudu hyvin training datalla.

Perustuu dia 6:n aineistoon: Model overfitting, validation, process models. Sisältö on rajattu kyselyssä heikommin hallittuihin kohtiin.