Kertaus: heikommin osatut asiat

Kertausdiojen 7-13 pohjalta • päätöspuut, satunnaismetsät, regressiot, klusterointi, assosiaatiosäännöt ja suosittelujärjestelmät

Miten tätä kannattaa lukea

Tämä ei ole kysymyspaketti vaan tiivis teoriakertaus. Sisältö painottaa niitä käsitteitä, jotka jäivät kyselyissä epävarmoiksi, osittaisiksi tai sekoittuivat toisiin käsitteisiin. Kertausdiojen ydinkohdat ovat kuitenkin mukana, jotta asiat pysyvät oikeassa kokonaisuudessa.

KERTAA ERITYISESTI

Gini ja ylisovittaminen • random forestin kaksi satunnaisuuden lähdettä • lineaarisen ja logistisen regression oletukset • WCSS ja alustuksen vaikutus • support vs confidence vs lift • Apriori-periaate • cosine similarity • painotettu keskiarvo suosittelussa.

- Dia 7: Päätöspuut
- Dia 8: Satunnaismetsät
- Dia 9: Lineaarinen regressio
- Dia 10: Logistinen regressio
- Dia 11: Klusterointi ja k-means
- Dia 12: Assosiaatiosäännöt
- Dia 13: Suosittelujärjestelmät

Dia 7 - Päätöspuut

Kertausdian painotus: mille datalle päätöspuu sopii, puun rakentaminen, Gini-indeksi ja lopetusehdot.

KERTAA ERITYISESTI: Gini + ylisovittaminen

Gini-indeksi mittaa solmun epäpuhtautta. Gini = 0 tarkoittaa puhdasta solmua, jossa kaikki havainnot kuuluvat samaan luokkaan. Puuta kasvatettaessa valitaan jako, joka tuottaa mahdollisimman puhtaat lapsisolmut. Ylisovittaminen (overfitting) tarkoittaa, että puu oppii harjoitusdatan yksityiskohtia ja kohinaa liian tarkasti eikä yleisty hyvin uuteen dataan.

Puun rakentamisen periaate

- Aloitetaan juurisolmusta, jossa ovat kaikki harjoitushavainnot.
- Kokeillaan eri piirteitä ja jakokohtia. Valitaan jako, joka parantaa luokkien erottelua eniten.
- Sama tehdään uusissa lapsisolmuissa uudelleen.
- Kasvatus loppuu, kun lopetusehto täyttyy; esimerkiksi solmu on puhdas tai puun syvyys / havaintomäärä rajoittaa kasvua.

Gini-indeksin idea

Gini on pieni, kun yksi luokka hallitsee solmua. Gini on suuri, kun luokat ovat sekoittuneet. Binäärisessä tai moniluokkaisessa luokittelussa tavoite on löytää jako, jonka painotettu Gini on mahdollisimman pieni.

$$g = 1 - \Sigma\, p_i^2$$

Ylisovittamisen hallinta

- max_depth rajoittaa puun syvyyttä.
- min_samples_split ja min_samples_leaf estävät hyvin pienten solmujen muodostamista.
- Mallia arvioidaan datalla, jota se ei nähnyt harjoittelussa.

Koevastaus: Päätöspuu jakaa dataa toistuvasti piirteiden perusteella. Gini-indeksillä valitaan jakoja, jotka tekevät lapsisolmuista mahdollisimman puhtaita. Liian syvä puu voi ylisovittaa.

Dia 8 - Satunnaismetsät

Kertausdian painotus: miten puihin luodaan satunnaisuutta ja miten metsän lopullinen ennuste muodostetaan.

KERTAA ERITYISESTI: mistä satunnaisuus tulee?

Random forestissa puut eivät saa olla keskenään samanlaisia. Satunnaisuutta luodaan kahdella tavalla: (1) jokaiselle puulle poimitaan satunnainen havaintosample takaisinpanolla eli bootstrap-otannalla ja (2) jakoa etsittäessä tarkastellaan vain satunnaista osajoukkoa piirteistä.

Bootstrap-otanta

Takaisinpanolla tehtävässä otannassa sama harjoitushavainto voi päätyä yhden puun harjoitusaineistoon useita kertoja ja osa havainnoista voi jäädä siitä pois.

Satunnainen piirrejoukko

Jokaisessa jaossa ei tarkastella kaikkia piirteitä. Tämä pienentää puiden keskinäistä korrelaatiota ja tekee metsästä monipuolisemman.

Metsän ennuste

- Luokittelussa jokainen puu antaa äänen luokalle.
- Koko metsän luokka on yleensä se, joka saa eniten ääniä.
- Useiden erilaisten puiden yhdistäminen tekee mallista yksittäistä päätöspuuta vakaamman ja yleensä vähemmän ylisovittavan.

Koevastaus: Random forest rakentaa monta päätöspuuta bootstrap-otoksilla ja satunnaisilla piirrejoukoilla. Luokittelussa lopputulos saadaan puiden enemmistöäänestyksellä.

Dia 9 - Lineaarinen regressio

Kertausdian painotus: numeerisen vastemuuttujan ennustaminen, mallin rakenne, residuaali, MAE ja ennakko-oletukset.

KERTAA ERITYISESTI: residuaali ja oletukset

Residuaali on ennusteen ja todellisen arvon erotus. Lineaarisen regression käyttöä pitää epäillä, jos yhteys ei ole lineaarinen, selittävät muuttujat ovat vahvasti keskenään riippuvia tai residuaalit käyttäytyvät järjestelmällisesti.

Mallin idea

Lineaarisella regressiolla ennustetaan numeerista vastemuuttujaa. Yhden selittävän muuttujan tapauksessa mallin perusmuoto on suora:

$$\hat{y} = b_0 + b_1 x$$

Residuaali

Residuaali kertoo, kuinka paljon yksittäinen ennuste poikkeaa todellisesta arvosta. Hyvässä mallissa residuaaleissa ei pitäisi näkyä selkeää rakennetta.

MAE - Mean Absolute Error

MAE on absoluuttisten ennustevirheiden keskiarvo. Mitä pienempi MAE, sitä lähempänä ennusteet ovat keskimäärin todellisia arvoja. MAE on samassa yksikössä kuin ennustettava muuttuja.

Ennakko-oletukset

- Lineaarisuus: selittävien muuttujien ja vastemuuttujan yhteyden pitäisi olla suunnilleen lineaarinen.
- Ei multikollineaarisuutta: selittävien muuttujien ei pitäisi olla liian vahvasti lineaarisesti riippuvia toisistaan.
- Residuaalit: niiden tulisi olla suunnilleen normaalijakautuneita, odotusarvoltaan 0 ja varianssiltaan suunnilleen vakioita.
- Heteroskedastisuus: residuaalien hajonta muuttuu ennustetason mukana; tämä rikkoo vakion varianssin oletusta.

Koevastaus: Lineaarinen regressio ennustaa numeerista arvoa. Residuaali on ennusteen ja todellisen arvon erotus, MAE mittaa absoluuttisen virheen keskiarvoa, ja mallin käyttö edellyttää muun muassa lineaarista yhteyttä sekä järkevästi käyttäytyviä residuaaleja.

Dia 10 - Logistinen regressio

Kertausdian painotus: todennäköisyysarvon ennustaminen, binäärinen luokittelu, suhde lineaariseen regressioon, sigmoidifunktio ja oletukset.

KERTAA ERITYISESTI: logistinen ≠ lineaarinen regressio

Logistisessa regressiossa lineaarinen yhdistelmä ei ole lopullinen ennuste. Se viedään sigmoidifunktion läpi, jolloin tulos rajautuu välille 0-1 ja voidaan tulkita todennäköisyydeksi. Tämän jälkeen kynnysarvo, esimerkiksi 0,5, muuttaa todennäköisyyden luokaksi.

Sigmoidifunktio

Sigmoidi muuntaa rajattoman lineaarisen tuloksen todennäköisyysasteikolle:

$$p = 1 / (1 + e^{(-z)})$$

- p lähellä 1 → havainto kuuluu todennäköisesti positiiviseen luokkaan.
- p lähellä 0 → havainto kuuluu todennäköisesti negatiiviseen luokkaan.

Log-loss

Log-loss rankaisee erityisesti tilanteista, joissa malli on hyvin varma mutta väärässä. Siksi pelkkä oikean luokan osuminen ei ole ainoa asia, vaan myös ennustetun todennäköisyyden laatu merkitsee.

Ennakko-oletukset

- Perusmuodossa vastemuuttuja on binäärinen.
- Havaintojen tulisi olla toisistaan riippumattomia.
- Selittävien muuttujien ei pitäisi olla täydellisesti tai erittäin vahvasti kollineaarisia.
- Selittäjien ja lopputuloksen log-oddsin välillä oletetaan lineaarinen yhteys.

Moniluokkainen käyttö

Logistisen regression perusidea on binäärinen, mutta moniluokkaista ongelmaa voidaan käsitellä esimerkiksi One-vs-Rest-ajattelulla, jossa yksi luokka erotetaan kerrallaan muista.

Koevastaus: Logistinen regressio ennustaa luokkaan kuulumisen todennäköisyyttä. Lineaarinen yhdistelmä muunnetaan sigmoidilla välille 0-1 ja luokaksi esimerkiksi 0,5-kynnyksellä.

Dia 11 - Klusterointi ja k-means

Kertausdian painotus: mittaamiseen perustuva ohjaamaton oppiminen, algoritmin eteneminen ja hierarkkinen klusterointi.

KERTAA ERITYISESTI: WCSS ja alustus

WCSS ei ole keskimääräinen etäisyys. Se on kaikkien havaintojen neliöityjen etäisyyksien summa omaan klusterikeskipisteeseensä. K-means pyrkii minimoimaan tämän arvon. Lisäksi eri alkuperäiset centroidit voivat johtaa eri lopputuloksiin, joten alustus vaikuttaa ratkaisuun.

K-meansin eteneminen

- Valitaan klusterien määrä k ja alustetaan k centroidia.
- Jokainen havainto liitetään lähimpään centroidiin, usein euklidisen etäisyyden perusteella.
- Jokaiselle klusterille lasketaan uusi centroidi sen havaintojen keskiarvona.
- Sijoitus ja centroidien päivitys toistetaan, kunnes ratkaisu ei enää muutu olennaisesti.

WCSS ja elbow method

Kun k kasvaa, WCSS pienenee lähes väistämättä. Siksi pienintä WCSS-arvoa ei voi vain valita suoraan. Elbow methodissa etsitään kohtaa, jonka jälkeen lisäklusterit pienentävät WCSS:ää enää vain vähän.

Alustuksen vaikutus

K-means voi päätyä eri paikallisiin ratkaisuihin eri alku-centroideilla. Siksi algoritmi voidaan ajaa useita kertoja eri alustuksilla ja valita paras tulos.

Hierarkkinen klusterointi

Agglomeratiivisessa hierarkkisessa klusteroinnissa jokainen havainto aloittaa omana klusterinaan, ja lähimpiä klustereita yhdistetään vaiheittain, kunnes muodostuu suurempia kokonaisuuksia.

Koevastaus: K-means vuorottelee havaintojen sijoittamista lähimpään centroidiin ja centroidien päivittämistä. WCSS on neliöityjen etäisyyksien summa omiin centroideihin; elbow method auttaa valitsemaan k:n.

Dia 12 - Assosiaatiosääntöjen etsintä

Kertausdian painotus: luokkamuuttujat, numeeristen muuttujien luokittelu, support-confidence-lift ja Apriori-algoritmin eteneminen.

KERTAA ERITYISESTI: support vs confidence vs lift

Support katsoo kaikkia tapahtumia. Confidence katsoo vain niitä tapahtumia, joissa vasen puoli X esiintyy. Lift vertaa X:n ja Y:n yhteisesiintymistä siihen, mitä odotettaisiin niiden ollessa riippumattomia.

Support - tuki

Säännölle X → Y support tarkoittaa niiden kaikkien tapahtumien osuutta, joissa esiintyy koko itemset X ∪ Y.

support(X → Y) = count(X ∪ Y) / kaikki tapahtumat

Confidence - luottamus

Confidence kertoo, kuinka suuressa osassa X:n sisältävistä tapahtumista esiintyy myös Y. Se voidaan tulkita ehdolliseksi todennäköisyydeksi P(Y|X).

confidence(X → Y) = count(X ∪ Y) / count(X)

Lift - noste

- lift > 1: X ja Y esiintyvät yhdessä useammin kuin riippumattomuus olettaisi.
- lift = 1: X:n esiintyminen ei muuta Y:n todennäköisyyttä; ne käyttäytyvät riippumattomasti.
- lift < 1: X ja Y esiintyvät yhdessä harvemmin kuin riippumattomuus olettaisi.

Apriori kahdessa vaiheessa

- 1) Etsitään frequent itemsetit alkaen yhden itemin joukoista ja kasvatetaan niitä vaiheittain min_support-rajan avulla.
- 2) Frequent itemseteistä muodostetaan mahdollisia sääntöjä ja niitä suodatetaan esimerkiksi min_confidence-rajalla.

Apriori-periaate

Jos suuremman itemsetin jokin osajoukko ei ole frequent, myöskään suurempi itemset ei voi olla frequent. Se voidaan siis karsia ilman turhaa laskentaa.

Liian pieni min_support

Tuottaa paljon frequent itemsettejä, kasvattaa laskentaa ja voi tuottaa suuren määrän harvinaisia tai käytännössä marginaalisia sääntöjä. Se ei kuitenkaan automaattisesti tarkoita, että confidence-arvojen keskiarvo laskisi.

Koevastaus: Support mittaa säännön koko itemsetin yleisyyttä, confidence Y:n yleisyyttä X:n tapauksissa ja lift yhteisesiintymistä suhteessa riippumattomuuteen.

Dia 13 - Suosittelujärjestelmät

Kertausdian painotus: yhteistoiminnallinen suodatus, item-based, user-based ja kosinisamankaltaisuus.

KERTAA ERITYISESTI: cosine similarity

Cosine similarity mittaa kahden vektorin suuntien samankaltaisuutta, ei ennustetun arvosanan hyvyyttä. Arvo 1 tarkoittaa samaa suuntaa, 0 kohtisuoruutta ja -1 vastakkaista suuntaa.

Collaborative filtering

Yhteistoiminnallinen suodatus tekee suosituksia käyttäjiltä kerättyjen reaktioiden perusteella, esimerkiksi arvioista, katseluhistoriasta tai ostoista.

Item-based vs user-based

- Item-based: verrataan tuotteiden arviointivektoreita keskenään. Suositus perustuu siihen, että käyttäjä on pitänyt samankaltaisista tuotteista.
- User-based: verrataan käyttäjien arviointivektoreita keskenään. Suositus perustuu siihen, että samankaltaisen maun omaavat käyttäjät ovat pitäneet tietystä tuotteesta.

Cosine similarity

Kosinisamankaltaisuuden peruskaava vertailee vektorien pistetuloa niiden pituuksiin:

$$\mathbf{sim(a,b) = (a \cdot b) / (|a||b|)}$$

Puuttuvan arvosanan ennustaminen

Pelkkä similarity-arvo ei vielä ole ennustettu arvosana. Puuttuva arvosana arvioidaan lähimpien tuotteiden tai käyttäjien tunnettujen arvosanojen samankaltaisuuksilla painotettuna keskiarvona.

$$\mathbf{ennuste = \Sigma(similarity \times rating) / \Sigma(similarity)}$$

Lopulliset suositukset

Kun puuttuvat arvosanat on ennustettu, käyttäjälle voidaan suositella tuotteita, joiden ennustettu arvosana on korkein.

Item-basedin rajoite

Hyvin samankaltaiset tuotteet voivat tehdä suosituksista liian ilmiselviä: esimerkiksi yhden sarjan elokuvasta pitävälle suositellaan vain saman sarjan toista osaa.

Koevastaus: Item-based vertaa tuotteita, user-based käyttäjiä. Samankaltaisuus voidaan laskea cosine similarityllä, ja puuttuva arvosana arvioidaan samankaltaisuuksilla painotettuna keskiarvona.

Viime hetken kertauslista

Jos aikaa on vain vähän, varmista että osaat selittää nämä ilman kaavoihin katsomista:

1. Overfitting

Malli oppii harjoitusdatan liian tarkasti, myös kohinan, ja yleistää huonosti uuteen dataan.

2. Gini

Solmun epäpuhtauden mitta päätöspuussa. Pienempi on puhtaampi; Gini = 0 tarkoittaa yhtä luokkaa.

3. Random forest

Bootstrap + satunnainen piirrejoukko + usean puun yhdistäminen.

4. Residuaali / MAE

Residuaali = ennusteen ja todellisen arvon ero. MAE = absoluuttisten virheiden keskiarvo.

5. Logistinen regressio

Lineaarinen yhdistelmä → sigmoid → todennäköisyys → kynnys → luokka.

6. WCSS

Neliöityjen etäisyyksien summa havaintojen ja niiden omien centroidien välillä.

7. Support / confidence / lift

Support = kaikista tapahtumista; confidence = X-tapauksista; lift = yhteys suhteessa riippumattomuuteen.

8. Apriori-periaate

Jos osajoukko ei ole frequent, sen sisältävä suurempi itemset voidaan karsia.

9. Cosine similarity

Mittaa vektorien suuntien samankaltaisuutta: 1 sama suunta, 0 kohtisuora, -1 vastakkainen.

10. Suosittelun painotettu ennuste

Puuttuva rating saadaan samankaltaisten käyttäjien tai itemien ratingeista similarity-arvoilla painotettuna keskiarvona.

Lähdepohja: kurssin Kertaus_v1-diat 7-13 sekä samoihin aiheisiin liittyvät tämän keskustelun kurssiliitteet. Sisältö on rajattu kertausdiojen painotuksiin ja kyselyissä esiin nousseisiin heikompiin kohtiin.