Kertaus: Data preprocessing → kNN → validointi

Yhtenäinen kertaus kaikista tähän asti käydyistä aiheista. Mukana kaikki keskeiset termit ja teoriat, painottaen kohtia, joissa kyselyissä tarvittiin tarkennusta.

1. Data preprocessing / datan esikäsittely

Datan esikäsittely tarkoittaa datan tarkistamista, puhdistamista ja muuntamista ennen mallintamista. Malli ei pysty automaattisesti korjaamaan huonolaatuista syötedataa, joten esikäsittely vaikuttaa suoraan mallin tuloksiin.

- GIGO (Garbage In, Garbage Out): huonolaatuinen data sisään → huonolaatuiset tai vääristyneet tulokset ulos.
- Ennen mallintamista tarkistetaan esimerkiksi puuttuvat arvot, virheelliset arvot, tietotyypit, kategorioiden yhtenäisyys ja muuttujien jakaumat.
- Muuttujien merkitys ja mittayksiköt pitää ymmärtää ennen kuin niitä käsitellään.

Muistisääntö

Esikäsittelyn tavoite ei ole tehdä datasta “siistiä” ulkonäön vuoksi, vaan estää virheitä ja harhaa myöhemmässä analyysissä.

2. Puuttuvat arvot

Puuttuvat arvot voivat vaikuttaa mallin toimintaan ja vääristää aineiston rakennetta. Niille ei ole yhtä aina oikeaa käsittelytapaa, vaan ratkaisu riippuu datasta ja puuttumisen syystä.

- Ignorointi: joskus mahdollista, mutta systemaattisesti puuttuva data voi vääristää tuloksia.
- Rivien poistaminen: voi toimia, jos puuttuvia arvoja on vähän ja ne ovat satunnaisia; haittana arvokkaan datan menetys.
- Sarakkeen poistaminen: mahdollinen, jos suuri osa koko muuttujasta puuttuu.
- Imputointi: puuttuva arvo korvataan esimerkiksi keskiarvolla, mediaanilla tai moodilla.
- Algoritmilla arviointi: puuttuva arvo ennustetaan muiden muuttujien perusteella; voi olla tarkempi mutta raskaampi.
- Asiantuntija-arvio: mahdollista, mutta voi tuoda subjektiivista harhaa.

Tärkeä tarkennus imputoinnista

Jos paljon puuttuvia arvoja korvataan samalla keskiarvolla, mediaanilla tai moodilla, aineistoon syntyy paljon keinotekoisesti samanlaisia arvoja. Tämä voi pienentää muuttujan vaihtelua (varianssia) ja vääristää jakaumaa.

3. Virheelliset arvot ja outlierit

Outlier on havainto, joka poikkeaa selvästi muusta datasta. Se voi olla mittaus- tai syöttövirhe, mutta se voi myös olla täysin validi harvinainen havainto.

- Outlieria ei pidä poistaa automaattisesti vain siksi, että se on harvinainen.
- Arvon järkevyyttä tarkastellaan suhteessa muuttujan merkitykseen ja mahdollisiin rajoihin.
- Esimerkiksi ihmisen paino 150 kg voi olla harvinainen mutta mahdollinen; 750 kg viittaisi vahvasti virheeseen.
- Virheellinen arvo voidaan esimerkiksi merkitä puuttuvaksi tai poistaa kyseinen rivi, jos siihen on perusteltu syy.

4. Tietotyypit ja kategorioiden yhtenäisyys

Muuttujan tietotyyppi määrää, millaisia operaatioita sille voidaan tehdä. Numeeriseksi tarkoitettu sarake voi esimerkiksi latautua merkkijonoksi, jos siellä on yksi tekstiarvo.

- Numeerisesta merkkijonosta ei voi laskea normaalisti esimerkiksi keskiarvoa ennen muunnosta numeroksi.
- Kategorisen muuttujan sama merkitys pitää esittää samalla tavalla koko aineistossa.
- Jos “mies” esiintyy sekä arvona 1 että tekstinä `Male`, järjestelmä voi tulkita ne eri luokiksi.

Muistisääntö

Sama asia eri koodeilla = data pirstoutuu virheellisesti. Ennen analyysiä kategoriat yhtenäistetään.

5. Visualisointi esikäsittelyssä

Visualisoinnit, kuten histogrammit, auttavat näkemään datan rakennetta nopeasti. Pitkästä taulukosta poikkeavat arvot, vinot jakaumat tai epärealistiset arvovälit voivat olla vaikeita huomata.

- Histogrammilla nähdään muuttujan jakauma, keskittyminen ja mahdolliset outlierit.
- Visualisointi voidaan tehdä uudelleen puhdistuksen jälkeen, jotta nähdään, vaikuttiko suodatus halutulla tavalla.
- Visualisointi ei yksin kerro, onko outlier virheellinen - löydetty havainto pitää vielä tulkita.

6. Korrelaatio ja kausaliteetti

Korrelaatio tarkoittaa, että kaksi muuttujaa muuttuvat tilastollisesti yhdessä. Korrelaatio voi olla positiivinen, negatiivinen tai hyvin heikko. Kausaliteetti tarkoittaa todellista syy-seuraussuhdetta.

- Korrelaatio ei todista, että toinen muuttuja aiheuttaa toisen muutoksen.
- Taustalla voi olla kolmas muuttuja, joka vaikuttaa molempiin.
- Siksi periaate “correlation does not imply causation” on tärkeä tulkinnassa.

Esimerkki

Kaksi asiaa voivat korreloida vahvasti, vaikka niiden välillä ei olisi suoraa syy-seuraussuhdetta. Kausaalipäätelmä vaatii enemmän näyttöä kuin pelkän korrelaation.

7. Luokittelu ja kNN

Luokittelussa mallin tehtävä on ennustaa havaintojen luokka. kNN (k-Nearest Neighbors) tekee ennusteen vertaamalla uutta havaintoa training-datan havaintoihin.

- k = kuinka monta lähintä naapuria tarkastellaan.
- Uuden havainnon etäisyys training-datan havaintoihin lasketaan.
- Valitaan k lähintä havaintoa.
- Luokaksi valitaan näiden naapureiden yleisin luokka, ei keskiarvo.

Esimerkki

Jos k = 5 ja lähimpien naapureiden luokat ovat A, A, B, A, B, ennuste on A (3 ääntä 5:stä).

8. Euklidinen etäisyys

kNN tarvitsee etäisyysmitan määrittääkseen, mitkä havainnot ovat “lähimpiä”. Numeerisilla jatkuvilla muuttujilla tavallinen valinta on euklidinen etäisyys.

Euklidinen etäisyys

```
d = sqrt((x1_i - x1_j)^2 + (x2_i - x2_j)^2 + ...)
```

Ajatus on sama kuin Pythagoraan lauseessa, mutta kaava toimii myös useammassa kuin kahdessa ulottuvuudessa.

9. Feature scaling ja standardointi

Koska kNN perustuu etäisyyksiin, eri mittakaavoissa olevat muuttujat voivat vääristää tulosta. Jos yhden muuttujan arvot ovat paljon suurempia kuin muiden, se voi dominoida etäisyyslaskentaa.

Standardointi

$$z = (x - \mu) / \sigma$$

Standardoinnin jälkeen training-datan sarakkeen keskiarvo on 0 ja keskihajonta 1.

- Standardointi antaa eri piirteille suunnilleen tasapuolisen mahdollisuuden vaikuttaa etäisyyteen.
- Uudet ennustettavat havainnot pitää standardoida samoilla training-datasta saaduilla keskiarvoilla ja keskihajonnoilla.
- Jos uusi havainto skaalataan eri tavalla, se ei ole samalla asteikolla training-datan kanssa ja etäisyydet vääristyvät.

10. Confusion matrix

Confusion matrix näyttää oikeiden luokkien ja mallin ennustamien luokkien suhteen. Moniluokkaisessa tapauksessa oikein luokitellut havainnot ovat matriisin diagonaalilla; diagonaalin ulkopuoliset arvot ovat virheluokituksia.

Termi	Merkitys binääriluokittelussa
TP	Oikeasti positiivinen ja ennustettu oikein positiiviseksi.
FP	Oikeasti negatiivinen, mutta ennustettu väärin positiiviseksi.
FN	Oikeasti positiivinen, mutta ennustettu väärin negatiiviseksi.
TN	Oikeasti negatiivinen ja ennustettu oikein negatiiviseksi.

11. Accuracy, precision ja recall

Accuracy

```
accuracy = (TP + TN) / (TP + FP + FN + TN)
```

Kuinka suuri osa kaikista ennusteista meni oikein.

Precision / täsmällisyys

```
precision = TP / (TP + FP)
```

Kun malli ennustaa positiivisen, kuinka suuri osa näistä ennusteista on oikeasti positiivisia?

Recall / saanto

```
recall = TP / (TP + FN)
```

Kuinka suuren osan kaikista oikeasti positiivisista tapauksista malli löysi?

Precision vs recall

Recallin kasvattaminen tarkoittaa usein enemmän positiivisia ennusteita. Se voi vähentää FN-arvoja mutta lisätä FP-arvoja, jolloin precision saattaa laskea. Tätä kutsutaan precision-recall tradeoffiksi.

Accuracy voi olla harhaanjohtava

Jos luokat ovat hyvin epätasapainossa, malli voi saada korkean accuracyn ennustamalla lähes aina enemmistöluokkaa. Tällöin precision ja recall voivat kertoa mallin hyödyllisyydestä enemmän.

12. Mallin arviointi uudella datalla

Luokittelijan suorituskykyä ei pitäisi arvioida vain samalla datalla, jolla se koulutettiin. Training-tulos voi olla liian optimistinen, koska malli on jo sovitettu juuri kyseiseen dataan.

Tärkein tavoite

Hyvän koneoppimismallin tavoite on yleistää uuteen, aiemmin näkemättömään dataan - ei vain saada mahdollisimman korkeaa training scorea.

13. Overfitting / ylioppiminen

Overfitting tarkoittaa, että malli mukautuu liian tarkasti training-datan yksityiskohtiin, kohinaan tai sattumanvaraisiin kuvioihin. Tällöin training-datalla tulos voi näyttää erittäin hyvältä, mutta uusi data ennustuu huonommin.

- Ylioppinut malli ei ole oppinut vain yleisiä rakenteita, vaan myös training-datan erityispiirteitä.
- Paljon piirteitä tai hyvin monimutkainen malli voi kasvattaa ylioppimisen riskiä.
- Tyypillinen merkki: training-suorituskyky on selvästi testisuorituskykyä parempi.

Muistisääntö

Training erittäin hyvä + uusi data selvästi heikompi = mahdollinen overfitting.

14. Validointi

Validointi tarkoittaa mallin testaamista datalla, jota ei ole käytetty mallin kouluttamiseen. Sen tarkoitus on arvioida mallin yleistymiskykyä ja havaita ylioppimista.

- Accuracy, precision ja recall pitäisi arvioida aiemmin näkemättömästä datasta.
- Training accuracy on usein korkeampi kuin test accuracy, koska malli on sovitettu training-dataan.
- Korkea training accuracy ei yksin kerro, että malli olisi hyödyllinen käytännössä.

15. Split validation

Split validationissa datasetti jaetaan kahteen osaan: training set kouluttaa mallin ja test set arvioi sen. Jako tehdään tavallisesti satunnaisesti.

- Esimerkiksi 70 % trainingiin ja 30 % testiin.
- `test_size` määrää testiin menevän osuuden.
- `random_state` ei määrää prosenttijakoa, vaan lukitsee satunnaisuuden siemenen, jotta sama jako saadaan uudelleen.
- Heikkous: testiin varattu osa ei osallistu kyseisen mallin koulutukseen. Tämä voi olla ongelma pienessä datasetissä.

Cherry picking

random_state-arvoa ei pidä kokeilla uudelleen ja uudelleen saadakseen parhaan testituloksen. Suotuisan jaon tarkoituksellinen valitseminen vääristää arviointia ja on cherry pickingia.

16. Cross-validation / ristiinvalidointi

Cross-validation käyttää dataa tehokkaammin erityisesti pienissä dataseteissä. Data jaetaan k foldiin, ja malli koulutetaan k kertaa.

- k tarkoittaa foldien lukumäärää, ei foldin kokoa.
- Jokaisella kierroksella $k-1$ foldia käytetään trainingiin ja yksi fold testaukseen.
- Jokainen fold toimii vuorollaan testidatana.
- Lopullinen suorituskyky muodostetaan kierrosten tulosten keskiarvosta.
- Esimerkiksi 10-fold cross-validation → 10 kierrosta.

Miksi pienelle datalle?

Yksittäinen satunnainen train/test-jako voi vaikuttaa paljon tulokseen. Cross-validation hyödyntää kaikki havainnot eri kierroksilla sekä trainingissa että testauksessa ja antaa yleensä vakaamman arvion.

17. Mallin monimutkaisuus ja featureiden määrä

Kun featureiden määrä kasvaa, mallilla on enemmän mahdollisuuksia löytää training-datasta myös sattumanvaraisia yhdistelmiä. Siksi mallin monimutkaisuuden kasvu voi kasvattaa overfitting-riskiä.

- Tavoite ei ole maksimoida featureiden määrää, vaan käyttää piirteitä, joista malli pystyy oppimaan yleistettäviä rakenteita.
- Mallin todellinen laatu näkyy vasta siinä, miten hyvin se toimii uudella datalla.

18. Tiivistetyt muistettavat erot

Asia	Muista tämä
Outlier	Poikkeava havainto ei automaattisesti tarkoita virhettä.
Imputointi	Sama täyttöarvo monelle havainnolle voi pienentää varianssia ja vääristää jakaumaa.
Korrelaatio	Yhteys ei yksin todista syy-seurausta.
kNN	k lähintä naapuria → yleisin luokka.
Standardointi	Training-datassa keskiarvo 0, keskihajonta 1; uusi data samalla scalerilla.
Precision	Kuinka moni positiiviseksi ennustettu oli oikeasti positiivinen?
Recall	Kuinka moni oikeasti positiivinen löydettiin?
Overfitting	Training hyvä, yleistyminen heikko.
random_state	Tekee satunnaisen jaon toistettavaksi; ei määrää jakoprosenttia.
k-fold CV	k = foldien määrä; k kierrosta; lopuksi tulosten keskiarvo.

Kokonaisuuden punainen lanka

1) Puhdista ja ymmärrä data. 2) Rakenna malli sopivalla asteikolla. 3) Arvioi ennusteita oikeilla mittareilla. 4) Varmista validoinnilla, että malli yleistyy uuteen dataan.

Lähdepohja: kurssin Data preprocessing and visualization, Classification and k-NN algorithm sekä Model overfitting, validation, process models -aineistot.