Kertaus

Keskeisiä seikkoja koetta varten

Lähtökohdat

- Koe on paperimuotoinen teoriakoe.
- Laskin mukaan.
- Kirjastoista (Numpy, Pandas, Sklearn, Surprise, Mlxtend jne.) riittää tunnistava osaaminen
  - koodia ei tarvitse osata tuottaa, mutta peruslukutaito koodiin tulee olla
    - tulee tunnistaa menetelmiin liittyvät luokkien nimet sekä tavanomaiset, toimintaa ohjaavat ja kuvaavasti nimetyt parametrit)

Johdanto

- Ohjattu ja ohjaamaton oppiminen
- Koneoppimisen tavoitteet
  - Erityisesti luokittelu, klusterointi, numeeristen arvojen ennustus, assosiaatiosääntöjen etsintä
  - Mallin ja ennustamisen käsitteet
- Datan taulukkoesitys (*dataframe*)

Datan esikäsittely ja visualisointi

- Esikäsittelyn merkitys datan laadulle
  - Muuttujien tyypit
  - Puuttuva data
  - Virheellinen data
- Esikäsittelyn tyypilliset työvaiheet
- Visualisoinnin merkitys
- Prosessimallien (CRISP-DM) merkitys

kNN ja luokittelijoiden hyvyysmitat

- kNN-algoritmin lähtökohdat
  - Etäisyyksien mitattavuus
- kNN-algoritmin eteneminen
- Tarkkuus
- Täsmällisyys
- Saanto

Ylioppiminen, validointi, prosessimallit

- Ylioppimisen käsite
  - Mistä aiheutuu?
  - Miten ilmenee?
- Validoinnin idea ja merkitys
- Validoinnin tavat
  - Ositusvalidointi
  - Ristiinvalidointi

Päätöspuut

- Minkälaiselle datalle toimii?
- Puun rakentamisen periaatteet ja algoritmin eteneminen
  - Haarautumiskriteerin valinta: Gini-indeksi
  - Lopetusehdot

Satunnaismetsät

- Satunnaisuuden luonti metsän puihin
  - Piirteiden valinta
  - Havaintojen valinta (otanta takaisinpanolla)
- Metsän ennusteen muodostus puiden ennusteiden perusteella

Lineaarinen regressio

- Lähestymistapa: ennustetaan numeerista vastemuuttujaa.
- Mallin rakenne
  - Erityisesti selittävien ja vastemuuttujien välinen riippuvuus.
- Residuaalin käsite
- Ennustevirheen mittaus (MAE)
- Lineaaristen regressiomallien ennakko-oletukset

Logistinen regressio

- Lähtökohta: todennäköisyysarvojen ennustus, binäärinen luokittelu
- Logistisen ja lineaarisen regressiomallin suhde.
  - Logistinen funktio (sigmoidifunktio)
- Logististen regressiomallien ennakko-oletukset

Klusterointi ja k-means

- Lähtökohdat:
  - Perustuu mittaamiseen kuten kNN
- Algoritmin eteneminen
- Hierarkkisen klusteroinnin periaatteet

Assosiaatiosääntöjen etsintä

- Lähtökohdat
  - Luokkamuuttujille soveltuva menetelmä
  - Numeeristen muuttujien muuntaminen luokkamuuttajiksi (informaatiota katoaa)
- Mitat: tuki, luottamus, noste
- Algoritmin eteneminen

Suosittelujärjestelmät

- Yhteistoiminnallisen suodatuksen idea
  - Tuotepohjainen
  - Käyttäjäpohjainen
- Kosinisamankaltaisuus