Indeksointi

Toistuvien hakukyselyiden tehostaminen

Metropolia

Oppimistavoitteet

1. Opitaan indeksien ja indeksoinnin merkitys relaatiotietokannan suorituskyvylle.
2. Opitaan laatimaan tietokannalle indeksointisuunnitelma sekä toteuttamaan indeksointi.

Indeksointi

- Indeksoinnilla tarkoitetaan aputietorakenteiden muodostamista tietokantatauluihin.
- Hyvin suunnitellut indeksit nopeuttavat tietyissä tilanteissa tietokantahakuja.
  - Indeksin ansiosta voidaan välttyä kaikkien tietueiden läpikäynniltä tietokantataulussa.
- Indeksointi on fyysisen tietokantasuunnittelun tärkein toimenpide.

Ongelma

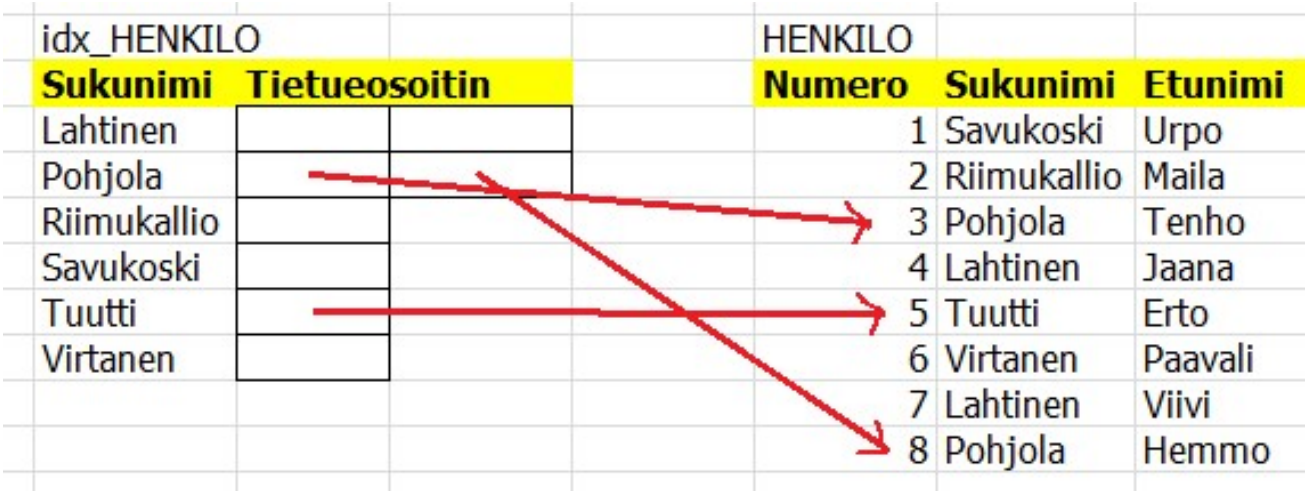
- Tarkastellaan tietokantatauluun kohdistuvaa kyselyä, jossa haetaan kaikkien Lahtinen-nimisten henkilöiden etunimet.
- ```
  SELECT Etunimi
  FROM HENKILO
  WHERE Sukunimi="Lahtinen";
  ```
- Tiedonhallintaohjelmiston on suoritettava **HENKILO**-tauluun peräkkäishaku.
  - Jokainen tietue on käytävä vuoron perään läpi ja tarkistettava siinä oleva **Sukunimi**-kentän arvo.
  - Ei ole mitään ”oikotietä”, jolla tiedonhallintaohjelmisto pystyisi löytämään Lahtiset.
  - Tämä hidastaa hakukyselyä, jos tietokantataulu on hyvin suuri.

HENKILO

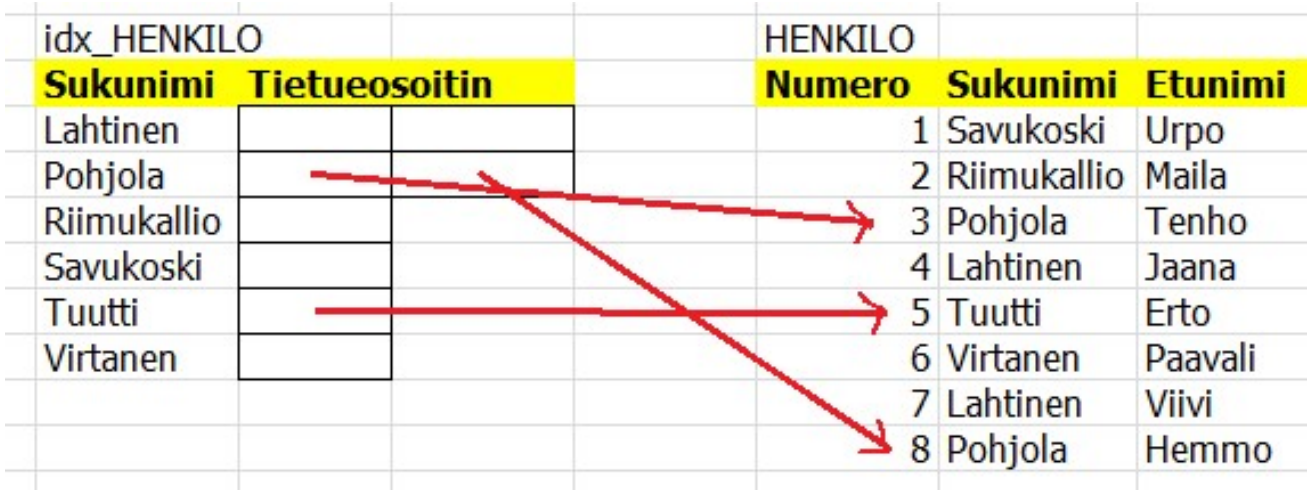
Numero	Sukunimi	Etunimi
1	Savukoski	Urpo
2	Riimukallio	Maila
3	Pohjola	Tenho
4	Lahtinen	Jaana
5	Tuutti	Erto
6	Virtanen	Paavali
7	Lahtinen	Viivi
8	Pohjola	Hemmo
  ```

Ratkaisu

- Muodostetaan indeksi sukunimen perusteella.
  - Indeksi on kuvassa vasemmalla.
- Haku sukunimen perusteella tapahtuu nyt indeksin kautta.
  1. Ensin etsitään indeksistä vastaava indeksitietue.
  2. Indeksitietueen perusteella löydetään tietokantataulun tietue tai tietueet.
- Kuvaan on merkitty selvyyden vuoksi vain sukunimistä Pohjola ja Tuutti lähtevät tietueosoittimet.



Miksi indeksi nopeuttaa?



- Tärkeä seikka: indeksitietueet on valmiiksi lajiteltu.
  - Esimerkissä indeksi on muodostettu sukunimelle, joten indeksitietueet on lajiteltu sukunimen perusteella.
- Oikea indeksitietue löytyy binäärihaulla korkeintaan 3 hakuaskeleella.
  - Binäärihaussa indeksiin on kyse samasta asiasta kuin jos etsittäisiin henkilön puhelinnumeroa vanhanaikaisesta paperisesta puhelinluettelosta: ensin katsotaan keskeltä, sitten valitun puoliskon keskeltä jne. kunnes nimi löytyy.
  - Yleisesti jos indeksissä on n tietuetta, löytyy indeksitietue korkeintaan $\log_2 n$ askeleessa.
- Indeksitietueen löytymisen jälkeen varsinaiset tietueet löytyvät 1 askeleessa.
  - Lahtinen ja Pohjola vaativat 2 askelta, koska tuloksena on 2 tietuetta.
- Jos indeksoitava kenttä olisi avain (ei välttämättä perusavain), vastaisi jokaista indeksitietuetta yksi datatietue.

Levylohkot ja sivut

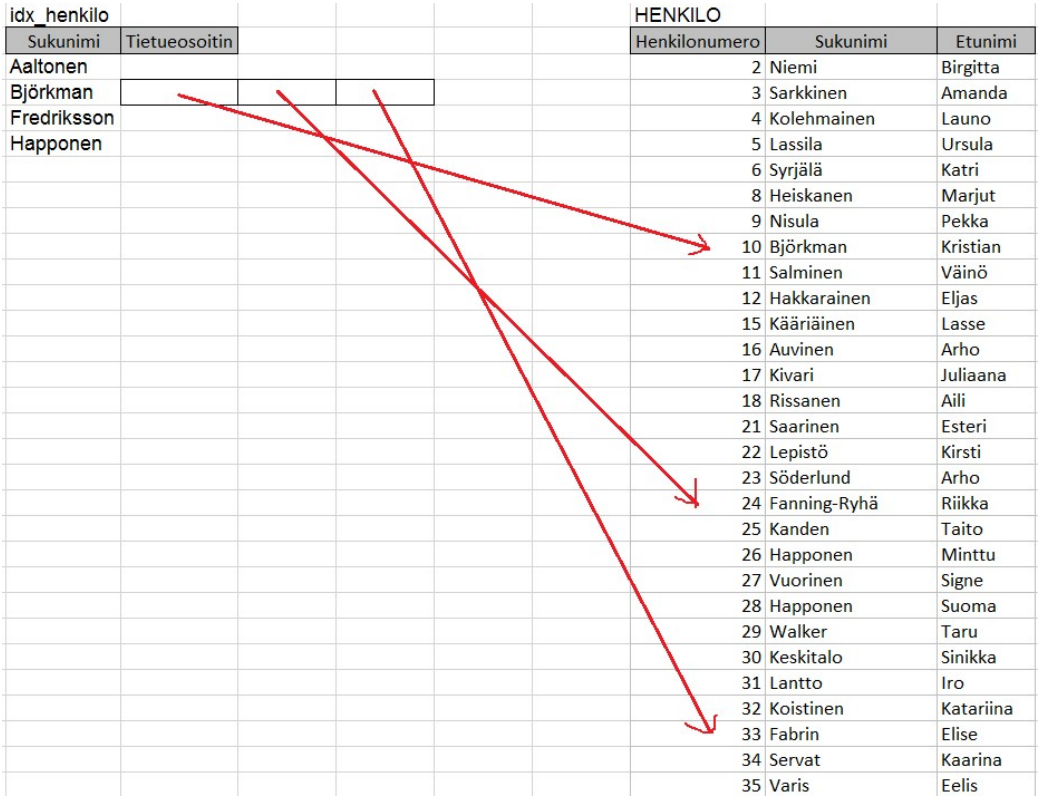
- Edellä esiteltiin indeksoinnin perusajatus.
- Käytännössä levyn luku- ja kirjoitusoperaatiot eivät tapahdu osoitteen tarkkuudella vaan
  - HDD-levyissä lohko kerrallaan (HDD).
  - SSD-levyissä sivu kerrallaan (SSD) lukuoperaatioissa ja suurempi lohko kerrallaan kirjoitusoperaatioissa.
- Indeksoinnista saatava hyöty säilyy:
  - Haettavien lohkojen/sivujen määrä pienenee.

Indeksointi perusavaimen perusteella

- Perusavaimelle rakennetaan indeksi automaattisesti.
- Myös viiteavain voidaan indeksoida automaattisesti.
  - Näin tapahtuu esim. MySQL:n INNODB-tauluissa.

Tiheä ja harva indeksi

- Aiempi esimerkki (sukunimet) esitti tiheää, yksitasoista indeksiä.
- Harvalla indeksillä tarkoitetaan tilannetta, jossa vain osa arvoista löytyy indeksitietueita.
  - Joudutaan lukemaan turhiakin datatietueita.
  - Toisaalta indeksi on pienempi ja siitä hakeminen on nopeaa.
- Esimerkkiin on yksinkertaisuuden vuoksi merkitty vain yhdestä sukunimestä lähtevät osoittimet.



idx_henkilo

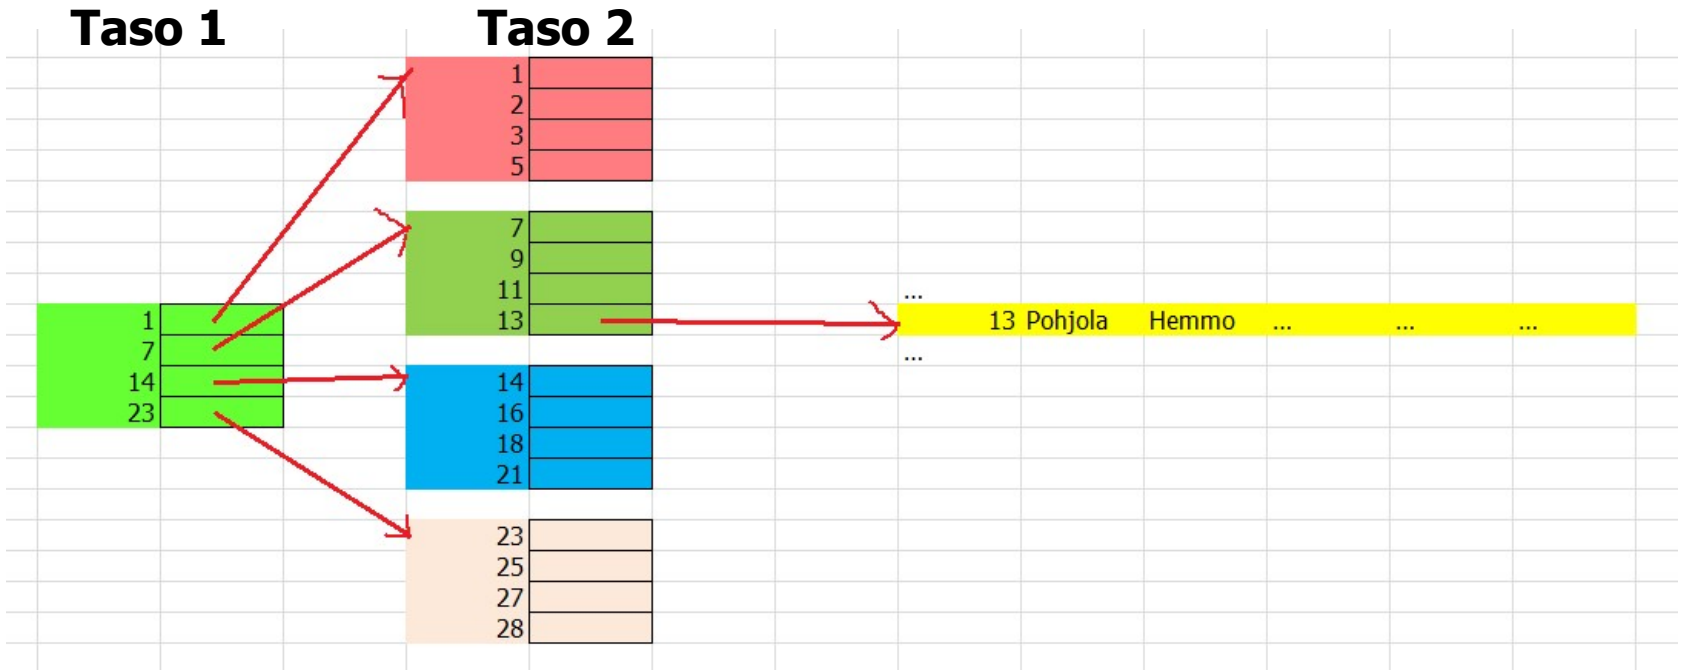
Sukunimi	Tietueosoitin
Aaltonen	
Björkman	
Fredriksson	
Happonen	

HENKILO

Henkilonumero	Sukunimi	Etunimi
2	Niemi	Birgitta
3	Sarkkinen	Amanda
4	Kolehmainen	Launo
5	Lassila	Ursula
6	Syrjälä	Katri
8	Heiskanen	Marjut
9	Nisula	Pekka
10	Björkman	Kristian
11	Salminen	Väinö
12	Hakkarainen	Eljas
15	Kääriäinen	Lasse
16	Auvinen	Arho
17	Kivari	Juliaana
18	Rissanen	Aili
21	Saarinen	Esteri
22	Lepistö	Kirsti
23	Söderlund	Arho
24	Fanning-Ryhä	Riikka
25	Kanden	Taito
26	Happonen	Minttu
27	Vuorinen	Signe
28	Happonen	Suoma
29	Walker	Taru
30	Keskitalo	Sinikka
31	Lantto	Iro
32	Koistinen	Katariina
33	Fabrin	Elise
34	Servat	Kaarina
35	Varis	Eelis

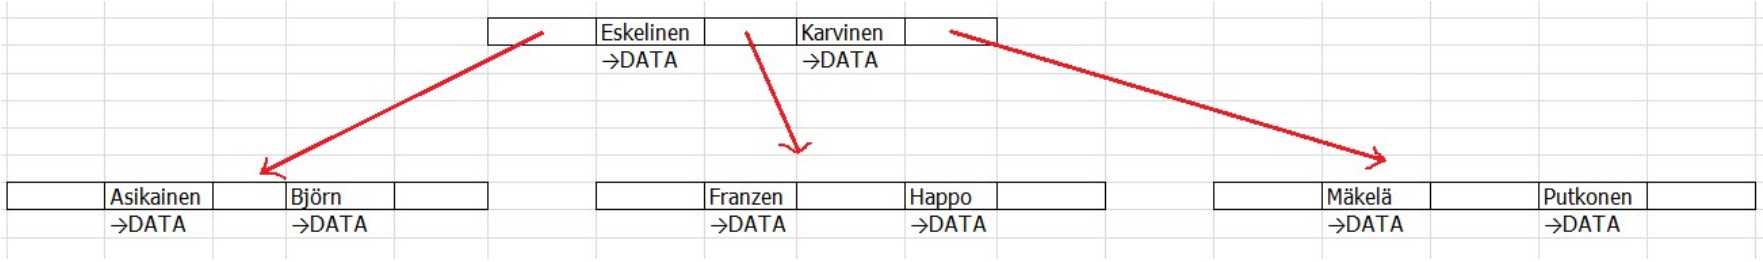
Monitasoinen indeksi

- Monitasoisessa indeksissä koko indeksi kullakin tasolla mahtuu yhteen lohkoon.
- Hakuavaruus kapenee nopeasti ja luettavia lohkoja tarvitaan vähän.



B-puuindeksi

- MariaDB- ja MySQL-tiedonhallintaohjelmistojen InnoDB-tietokantamoottori käyttää indeksin toteuttamiseksi B-puu-tietorakennetta.
- Esimerkin B-puussa kustakin solmusta lähtee korkeintaan kolme alipuuta.
- Solmut sisältävät myös tietueosoittimia ($\rightarrow$DATA).
- Lisäys- ja poisto-operaatiot on toteutettu siten, että puu säilyy tasapainoisena.
  - Solmuja lisätään tai yhdistetään dynaamisesti.
  - Algoritmit ovat jokseenkin monimutkaisia eikä niitä käsitellä tässä.
- Rakenteesta on useita muunnelmia
  - B+-puussa tietueosoittimia on vain rakenteen alimmilla tasoilla.



Indeksin luonti

- Indeksi luodaan **`CREATE INDEX`** -lauseella.
- Lauseet liitetään yleensä tietokantaskriptiin **`CREATE TABLE`** -lauseiden jälkeen.
- Esimerkkejä:
  - ```
    CREATE INDEX idx_etunimi
    ON HENKILO(Etunimi);
    ```
  - ```
    CREATE INDEX idx_kokonimi
    ON HENKILO(Sukunimi, Etunimi);
    ```

Indeksoinnin heuristiikkoja

- Tärkein heuristiikka: **tee indeksointi siten, että toistuvat haut nopeutuvat**.
  - Esim. web-palvelimelta tulevat haut ovat keskenään samantyyppisiä: vain parametri vaihtelee.
  - Vaikkapa henkilön haku sukunimen alkuosan perusteella (parametri alleviivattu):
    - ```
      SELECT Etunimi
      FROM HENKILO
      WHERE Sukunimi LIKE "Laht%";
      ```
  - Nyt kannattaa indeksoida sukunimen perusteella. Sen avulla sukunimen alkuosaa vastaavat indeksitietueet – ja sitä kautta varsinaiset tietueet löytyvät nopeasti.
- Indeksoinnin järkevyyttä voi pohtia peukalosääntöjen avulla:
  - Indeksit ovat hyödyllisimmillään suurissa tauluissa.
  - Indeksointi kannattaa tehdä kentille, jotka esiintyvät usein SQL-kyselyn WHERE-osassa
    - Liitosehdossa tai
    - Hakua rajaavassa ehdossa
  - Lajittelun tai ryhmittelyn perusteena oleva kenttä voi hyötyä indeksistä
    - ORDER BY
    - GROUP BY
  - Indeksoitavan kentän arvon on vaihdeltava riittävästi.
    - Jos lähes kaikissa tietueissa on sama arvo ja joka tietue haetaan indeksin kautta, voi haku hidastua.
  - NULL-arvoja ei välttämättä liitetä indeksiin, joten niitä käsittelevät haut saattavat johtaa peräkkäishakuun.
- Indeksointisuunnitelman laatiminen on osa fyysistä tietokantasuunnittelua.
- Indeksoinnin vaikutusta suoritusaikoihin kannattaa selvittää simuloimalla.
  - MariaDB/MySQL-tiedonhallintaohjelmiston apuohjelma **`mysqlslap`**.
      ```

Indeksointi ja nopeat levyt

- SSD-kiintolevyt (*solid state drive*) nopeuttavat levyhakuja huomattavasti aiempiin HDD-levyihin verrattuna.
- Tarvitaanko indeksejä, kun levy on nopea?
- Vastaus on kyllä, sillä:
  - SSD-levyjen suorituskykyparannus on
    - Vähäisempi peräkkäisluvussa (*sequential reads*), koska massaluku järjestyksessä ei edellytä HDD-levyltä toistuvia luku-/kirjoituspään kohdistamisia.
      - Parhaimmillaan HDD (10000 rpm): 600 MB/s, SSD: 3,5 GB/s
    - Suurempi osoitteellisessa lukemisessa (*random access*).
      - HDD edellyttää luku-/kirjoituspään siirtymistä ja levyn pyörimistä oikealle kohdalle.
      - SSD-levyltä voidaan lukea heti, kaikista osoitteista yhtä nopeasti.
- SSD-levyt edut korostuvat indeksoitaessa.
  - Juuri peräkkäishaussa SSD-levyn hyödyt jäävät vähäisemmiksi.
  - Indeksoinnilla vältetään peräkkäishakuja, ja lisäksi indeksin käyttö (joka on osoitteellista lukemista), on SSD-levyissä erityisen tehokasta.
- SSD-levyt kuitenkin nostavat kynnystä, jossa indeksointi tulee tarpeelliseksi ja hyödylliseksi.
  - Jonkin verran entistä suuremmasta datamäärästä voitaisiin selvitä ilman indeksointia.

Indeksoinnin varjopuolet

- Hidastaa lisäys-, poisto- ja päivitysoperaatioita.
  - Datan päivittämisen lisäksi on päivitettävä indeksejä.
  - Myös indeksejä, joita ei koskaan käytetä, joudutaan päivittämään.
- Vie levytilaa.
- Hidastaa kyselyn optimointia tarjoamalla kyselylle uuden toteutustavan.
- Hyvin suunnitellun indeksoinnin edut päihittävät nämä varjopuolet.